Théorie des probabilités — Cours

Ivan Lejeune

13 novembre 2024

Table des matières

Chapitre 1 — Bases de la théorie des probabilités

1 Espaces probabilisés

1.1 Probabilité

Définition 1.1. Soit $(\Omega, \mathscr{F})$ un espace mesurable. Une **mesure** sur $(\Omega, \mathscr{F})$ est une application

$$\begin{aligned} \mu \colon \mathscr{F} &\to [0, +\infty] \\ A &\mapsto \mu(A) \end{aligned}$$

qui vérifie les propriétés suivantes :

1. $\mu(\varnothing) = 0$
2. μ est σ-additive, c'est-à-dire que pour toute suite $(A_n)_{n\in\mathbb{N}}$ d'éléments 2 à 2 disjoints de $\mathscr{F}$, on a
$$\mu\left(\bigcup_{n\in\mathbb{N}} A_n\right) = \sum_{n\in\mathbb{N}} \mu(A_n)$$

On dit alors que $(\Omega, \mathscr{F}, \mu)$ est un **espace mesuré**.
Si de plus $\mu(\Omega) = 1$, on dit que $(\Omega, \mathscr{F}, \mu)$ est un **espace probabilisé** et μ est une **probabilité**.
On notera alors $\mu = \mathbb{P}$.

Remarque. Comme $\mathbb{P}(\Omega) = 1$, une mesure de probabilité est une mesure dans $[0, 1]$. Un événement A est dit **presque sûr** si $\mathbb{P}(A) = 1$.

Exemples 1.2.

1. Soit $(\Omega, \mathscr{F})$ un espace mesurable et ω un élément fixé dans Ω. La mesure (ou masse) de Dirac en ω est la mesure définie pour tout $A \in \mathscr{F}$ par
$$\delta_\omega(A) = \begin{cases} 1 & \text{si } \omega \in A \\ 0 & \text{sinon} \end{cases} = \mathbb{1}_A(\omega)$$
On vérifie facilement que c'est bien une probabilité.
2. Sur le segment $[0, 1]$ muni de sa tribu borélienne, la mesure de Lebesgue est une probabilité.
3. Si $(\Omega, \mathscr{F}, \mu)$ est un espace mesuré avec $0 < \mu(\Omega) < +\infty$, alors on obtient une probabilité en considérant la mesure
$$\mathbb{P} = \frac{\mu(\cdot)}{\mu(\Omega)}$$

Interprétation. Un espace probabilisé est donc un cas particulier d'espace mesuré pour lequel la masse totale de la mesure est égale à 1. En fait, le point de vue diffère de la théorie de l'intégration : dans le cadre de la théorie des probabilités, on cherche à fournir un modèle mathématique pour une “expérience aléatoire”.

- L'ensemble Ω est appelé **univers** : il représente l'ensemble de toutes les éventualiés possibles, toutes les déterminations du hasard dans l'expérience considérée. Les éléments ω de Ω, parfois appelés **événements élémentaires**, correspondent donc aux issues possibles de l'expérience aléatoire.
- La tribu $\mathscr{F}$ correspond à l'ensemble des **événements** : ce sont les parties de Ω dont on peut évaluer la probabilité. Il faut voir un événement A de $\mathscr{F}$ comme un sous-ensemble de Ω contenant toutes les éventualités ω pour lesquelles une certaine propriété est vérifiée.
- On associe à chaque événement $A \in \mathscr{F}$ un réel $\mathbb{P}(A) \in [0, 1]$ qui donne la plausibilité que le résultat de l'expérience soit dans A.

1.3 Exemples d'espaces probabilisés

Suivent quelques exemples classiques d'espaces probabilisés.

Exemples 1.4. cours a completer

2 Variables aléatoires

2.1 Loi d'une variable aléatoire

Définition 2.2. Soit $(\Omega, \mathscr{F}, \mathbb{P})$ un espace probabilisé et $(E, \mathscr{E})$ un espace mesurable. Une **variable aléatoire** est une application

$$X : \Omega \to E$$

mesurable. C'est-à-dire

$$\forall A \in \mathscr{E}, X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\} \in \mathscr{F}$$

Si $E = \mathbb{R}$ et $\mathscr{E} = \mathscr{B}(\mathbb{R})$, on parle de **variable aléatoire réelle**.
Si $E = \mathbb{R}^d$ et $\mathscr{E} = \mathscr{B}(\mathbb{R}^d)$, on parle de **variable aléatoire vectorielle**.

Exemples 2.3.
▷ Lancer de deux dés.
On considère l'expérience aléatoire qui consiste à lancer deux dés équilibrés. Alors

$$\Omega = \{1, \dots, 6\}^2, \quad \mathscr{F} = \mathscr{P}(\Omega).$$

On s'intéresse à la somme des résultats obtenus et on définit

$$\begin{aligned} X : \Omega &\to \{2, \dots, 12\} \\ (i,j) &\mapsto i + j \end{aligned}$$

On munit l'ensemble d'arrivée de la tribu pleine.
X est une variable aléatoire car l'espace de départ est muni de la tribu pleine.
▷ Infinité de lancers d'un dé.
On considère l'expérience aléatoire qui consiste à lancer un dé équilibré une infinité de fois. Alors

$$\Omega = \{1, \dots, 6\}^{\mathbb{N}^*} = \{\omega = (\omega_n)_{n \in \mathbb{N}^*} \mid \omega_n \in \{1, \dots, 6\}\}$$

On considère la tribu $\mathscr{F}$ la plus petite tribu contenant les $A_{x_1,\dots,x_k}$. On s'intéresse au nombre de lancers jusqu'à l'apparition du premier 6. On définit

$$\begin{aligned} Y : \Omega &\to \mathbb{N}^* \cup \{+\infty\} \\ \omega = (\omega_n)_{n \in \mathbb{N}^*} &\mapsto \inf\{n \in \mathbb{N}^* \mid \omega_n = 6\} \end{aligned}$$

avec la convention $\inf \varnothing = +\infty$. On munit l'ensemble d'arrivée de la tribu pleine.
Pour $k \geq 1$, on a

$$\begin{aligned} Y^{-1}(\{k\}) &= \{\omega = (\omega_n)_{n \in \mathbb{N}^*} \mid \omega_1 \neq 6, \dots, \omega_{k-1} \neq 6, \omega_k = 6\} \\ &= \bigcup_{x_1,\dots,x_{k-1} \in \{1,\dots,5\}} A_{x_1,\dots,x_{k-1},6} \in \mathscr{F} \end{aligned}$$

Par ailleurs,

$$\begin{aligned} Y^{-1}(\{+\infty\}) &= \{\omega = (\omega_n)_{n \in \mathbb{N}^*} \mid \forall n \in \mathbb{N}^*, \omega_n \neq 6\} \\ &= \bigcap_{k=1}^{+\infty} \bigcup_{x_1,\dots,x_k \in \{1,\dots,5\}} A_{x_1,\dots,x_k} \in \mathscr{F} \end{aligned}$$

Comme $\mathbb{N} \cup \{+\infty\}$ est dénombrable, on en déduit que Y est une variable aléatoire.

▷ Bouteille à la mer.
On considère l'expérience aléatoire qui consiste à observer la position d'une bouteille à la mer. Alors

$$\Omega = \mathscr{C}^0([0,1], \mathbb{R}^2)$$

On considère la tribu $\mathscr{F}$ la plus petite tribu rendant mesurables les applications coordonnées

$$\begin{aligned} f_t : \Omega &\to \mathbb{R}^2 \\ \omega &\mapsto \omega(t) \end{aligned}$$

On s'intéresse à la position de la bouteille au temps $t = 1$. On définit

$$\begin{aligned} Z : \Omega &\to \mathbb{R}^2 \\ \omega &\mapsto \omega(1) \end{aligned}$$

Alors, par construction de la tribu $\mathscr{F}$, on a que Z est une variable aléatoire.

Définition 2.4. Soit X une variable aléatoire de $(\Omega, \mathscr{F}, \mathbb{P})$ dans $(E, \mathscr{E})$. La **loi** de X est la mesure image de X par $\mathbb{P}$, définie par

$$\forall A \in \mathscr{E}, \mathbb{P}_X(A) = \mathbb{P}(X^{-1}(A)) = \mathbb{P}(X \in A)$$

Exemples 2.5.
▷ Infinité de lancers d'un dé.
On considère

$$\begin{aligned} Y : \Omega = \{1, \dots, 6\}^{\mathbb{N}^*} &\to \mathbb{N}^* \cup \{+\infty\} \\ \omega = (\omega_n)_{n \in \mathbb{N}^*} &\mapsto \inf\{n \in \mathbb{N}^* \mid \omega_n = 6\} \end{aligned}$$

La loi $\mathbb{P}_Y$ de Y est une mesure de probabilité sur $\mathbb{N}^* \cup \{+\infty\}$.
Soit $k \in \mathbb{N}^*$. On a

$$\begin{aligned} \mathbb{P}_Y(\{k\}) &= \mathbb{P}(Y^{-1}(\{k\})) \\ &= \mathbb{P}(Y = k) \\ &= \mathbb{P}\left(\bigcup_{x_1, \dots, x_{k-1} \in \{1, \dots, 5\}} A_{x_1, \dots, x_{k-1}, 6} \right) \\ &= \sum_{x_1, \dots, x_{k-1}} \underbrace{\mathbb{P}(A_{x_1, \dots, x_{k-1}, 6})}_{= \frac{1}{6^k}} \\ &= \frac{5^{k-1}}{6^k} \qquad = \left(\frac{5}{6}\right)^{k-1} \frac{1}{6} \end{aligned}$$

Par ailleurs, on a vu à la fin de la section précédente que la probabilité de ne jamais obtenir de 6 est nulle :

$$\mathbb{P}_Y(\{+\infty\}) = \mathbb{P}(Y^{-1}(\{+\infty\})) = \mathbb{P}(Y = +\infty) = 0$$

On en déduit que la loi de Y est

$$\sum_{k=1}^{+\infty} \left(\frac{5}{6}\right)^{k-1} \frac{1}{6} \delta_k$$

Cette loi est appelée **loi géométrique** de paramètre $\frac{5}{6}$.

Définition 2.6 Variable aléatoire discrète. Une variable aléatoire X est dite **discrète** si X est à valeurs dans un ensemble E au plus dénombrable. On prend alors $\mathscr{E} = \mathscr{P}(E)$ et si $A \in \mathscr{E}$, on a

$$\mathbb{P}_X(A) = \mathbb{P}(X \in A) = \mathbb{P}(X \in \cup_{x \in A} \{x\}) = \sum_{x \in A} \mathbb{P}(X = x)$$

La loi $\mathbb{P}_X$ de X est alors entièrement déterminée par les quantités $p_x = \mathbb{P}(X = x)$ pour tout $x \in E$:

$$\mathbb{P}_X(A) = \sum_{x \in E} p_x \delta_x$$

Définition 2.7 Variable aléatoire à densité. Une variable aléatoire X à valeurs dans $(\mathbb{R}^d, \mathscr{B}(\mathbb{R}^d))$ est dite **à densité** par rapport à la mesure de Lebesgue λ_d si il existe une fonction mesurable

$$f : \mathbb{R}^d \to [0, +\infty[$$

telle que $\mathbb{P}_X = f \lambda_d$:

$$\forall A \in \mathscr{B}(\mathbb{R}^d), \mathbb{P}_X(A) = \int_A f(x)\, d\lambda_d(x)$$

Il faut que f vérifie

$$\int_{\mathbb{R}^d} f(x)\, d\lambda_d(x) = 1$$

Par exemple, si $d = 1$, on a

$$\mathbb{P}_X([a,b]) = \int_a^b f(x)\, d\lambda_1(x)$$

On notera souvent $f_X = f$ et on appelle cette fonction la **densité** de X.

2.8 Lois usuelles

▷ Lois discrètes :
Loi uniforme sur un ensemble fini $\{x_1, \dots, x_n\}$.
Soit $E = \{x_1, \dots, x_n\}$ un ensemble fini.
Une variable aléatoire X suit une loi uniforme sur E, notée $X \sim \mathcal{U}(E)$, si sa loi est

$$\mathbb{P}_X = \frac{1}{n} \sum_{i=1}^n \delta_{x_i}$$

c'est-à-dire

$$\mathbb{P}_X(A) = \mathbb{P}(X \in A) = \frac{\mathrm{card}(A)}{n}$$

▷ Loi de Bernoulli.
Une variable aléatoire X suit une loi de Bernoulli de paramètre $p \in [0,1]$, notée $X \sim \mathcal{B}(p)$, si sa loi est

$$\mathbb{P}_X = p\delta_1 + (1-p)\delta_0$$

c'est-à-dire

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p$$

▷ Loi binomiale.
Une variable aléatoire X suit une loi binomiale de paramètres $n \in \mathbb{N}^*$ et $p \in [0,1]$, notée $X \sim \mathcal{B}(n,p)$, si sa loi est

$$\mathbb{P}_X = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} \delta_k$$

cela correspond au nombre de succès dans n répétitions d'une expérience de Bernoulli de paramètre p (de manière indépendante).
▷ Loi géométrique.
Une variable aléatoire X suit une loi géométrique de paramètre $p \in]0,1]$, notée $X \sim \mathcal{G}(p)$, si sa loi est

$$\mathbb{P}_X = \sum_{k=1}^{+\infty} p(1-p)^{k-1} \delta_k$$

c'est-à-dire

$$\mathbb{P}(X = k) = p(1-p)^{k-1}$$

cela correspond au nombre de répétitions d'une expérience de Bernoulli de paramètre p avant le premier succès.
▷ Loi de Poisson.
Une variable aléatoire X suit une loi de Poisson de paramètre $\theta > 0$, notée $X \sim \mathcal{P}(\theta)$, si sa loi est

$$\mathbb{P}_X = \sum_{k=0}^{+\infty} \frac{\theta^k}{k!} e^{-\theta} \delta_k$$

c'est-à-dire

$$\mathbb{P}(X = k) = \frac{\theta^k}{k!} e^{-\theta}$$

cela correspond au nombre d'événements rares dans un intervalle de temps donné.
▷ Lois à densité sur $\mathbb{R}^d$:
Loi uniforme sur un ensemble A de $\mathbb{R}^d$.
Soit $A \in \mathscr{B}(\mathbb{R}^d)$, telle que $0 < \lambda_d(A) < +\infty$. Une variable aléatoire X suit une loi uniforme sur A, notée $X \sim \mathcal{U}(A)$, si sa loi est

$$\mathbb{P}_X = \frac{1}{\lambda_d(A)} \mathbb{1}_A$$

c'est-à-dire $\mathbb{P}_X$ admet la densité constante $\frac{1}{\lambda_d(A)} \mathbb{1}_A$. Autrement dit, si $B \in \mathscr{B}(\mathbb{R}^d)$, on a

$$\mathbb{P}_X(B) = \int_B \frac{1}{\lambda_d(A)} \mathbb{1}_A(x)\, d\lambda_d(x) = \frac{\lambda_d(A \cap B)}{\lambda_d(A)}$$

dans le cas $d = 1$ et $A = [a, b]$, la densité est $f(x) = \frac{\mathbb{1}_{[a,b]}(x)}{b-a}$.
▷ Loi exponentielle.
Une variable aléatoire X suit une loi exponentielle de paramètre $\theta > 0$, notée $X \sim \mathcal{E}(\theta)$, si sa loi est

$$\mathbb{P}_X = \theta e^{-\theta x} \lambda_1 \mathbb{1}_{\mathbb{R}^+}$$

c'est-à-dire $\mathbb{P}_X$ admet la densité $f_X(x)\theta e^{-\theta x} \mathbb{1}_{\mathbb{R}^+}$ par rapport à la mesure de Lebesgue λ_1. Autrement dit, si $A \in \mathscr{B}(\mathbb{R})$, on a

$$\mathbb{P}_X(A) = \int_A \theta e^{-\theta x} \mathbb{1}_{\mathbb{R}_+}(x)\, d\lambda_1(x)$$

dans le cas $d = 1$. Cette loi vérifie la propriété de l'absence de mémoire, c'est-à-dire

$$\forall s, t \geq 0, \mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$$

▷ Loi normale ou gaussienne.
Une variable aléatoire X suit une loi normale de paramètres $\mu \in \mathbb{R}$ et $\sigma > 0$, notée $X \sim \mathcal{N}(\mu, \sigma^2)$, si sa loi est

$$\mathbb{P}_X = f_X \lambda_1$$

où f_X est la densité de la loi normale, donnée par

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Autrement dit, si $A \in \mathscr{B}(\mathbb{R})$, on a

$$\mathbb{P}_X(A) = \int_A \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\, d\lambda_1(x)$$

remarque, la loi $\mathcal{N}(,)$, c'est-à-dire avec la densité

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

est appelée loi normale standard.

3 Moments d'une variable aléatoire

On considère dans la suite $(\Omega, \mathscr{F}, \mathbb{P})$ un espace probabilisé

3.1 Espérance

Définition 3.2. Soit $X : \Omega \to \mathbb{R}$ une variable aléatoire réelle. On appelle **espérance** de X la quantité

$$\mathbb{E}[X] = \int_\Omega X(\omega)\, d\mathbb{P}(\omega)$$

qui est bien définie si X est positive ou si $X \in \mathscr{L}^1(\Omega, \mathscr{F}, \mathbb{P})$.
On définit de même l'espérance d'une variable aléatoire $X : \Omega \to \mathbb{C}$. Sk $X = (X_1, \dots, X_d)$ est un vecteur aléatoire, alors on pose

$$\mathbb{E}[X] = (\mathbb{E}[X_1], \dots, \mathbb{E}[X_d])$$

si $\mathbb{E}[X_i]$ existe pour tout $i \in \{1, \dots, d\}$.

Remarque.

1. On interprète $\mathbb{E}[X]$ comme la valeur moyenne de X.
2. Si $\mathbb{E}[X] = 0$, on dit que X est **centrée**.
3. Si $X = \mathbb{1}_A$, alors $\mathbb{E}[X] = \mathbb{P}(A)$.
4. On omettra le cas où X est positive et $\mathbb{E}[X] = +\infty$.

Proposition. Soient X et Y deux variables aléatoires admettant une espérance et $a, b \in \mathbb{R}$. Alors

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

De plus, si $X > 0$, alors $\mathbb{E}[X] \geq 0$ avec $\mathbb{E}[X] = 0$ si et seulement si $X = 0$-$\mathbb{P}$-p.p.

Proposition. Soit $X : \Omega \to E$ une variable aléatoire à valeurs dans un espace mesurable$(E, \mathscr{E})$.
Soit $h : E \to \mathbb{R}$ une fonction mesurable positive.
Alors, $h \circ X$ est une variable aléatoire et

$$\begin{aligned}\mathbb{E}[h(X)] &= \int_\Omega h(X(\omega))\, d\mathbb{P}(\omega) \\ &= \int_E h(x)\, d\mathbb{P}_X(x)\end{aligned}$$

Si $h : E \to \mathbb{R}$ et mesurable (pas forcément positive), alors $h \in \mathscr{L}^1(E, \mathscr{E}, \mathbb{P}_X)$ si et seulement si $h \circ X \in \mathscr{L}^1(\Omega, \mathscr{F}, \mathbb{P})$ et l'égalité précédente reste vraie.

Démonstration. Vue en théorie de la mesure.
On vérifie l'égalité :

- pour les fonctions indicatrices,
- pour les fonctions étagées,
- pour les fonctions positives,
- pour les fonctions intégrables

□

Remarque. En particulier, si $E = \mathbb{R}$ et $h = \mathrm{Id}_\mathbb{R}$, on obtient

$$\mathbb{E}[X] = \int_\mathbb{R} x\, d\mathbb{P}_X(x)$$

à condition que cette quantité existe.

Exemples 3.3. Loi de Bernoulli

$$\mathbb{P}_X = (1-p)\delta_0 + p\delta_1$$

$$\begin{aligned}
\mathbb{E}[X] &= \int_{\mathbb{R}} x \, d\mathbb{P}_X(x) \\
&= \int_{\mathbb{R}} x \, d\left((1-p)\delta_0 + p\delta_1\right)(x) \\
&= (1-p) \underbrace{\int_{\mathbb{R}} x \, d\delta_0(x)}_{=0} + p \underbrace{\int_{\mathbb{R}} x \, d\delta_1(x)}_{=1} \\
&= p
\end{aligned}$$

Si X suit une loi discrète

$$\mathbb{P}_X = \sum_{k=1}^{\infty} p_k \delta_{i_k}$$

alors son espérance vaut

$$\begin{aligned}
\mathbb{E}[X] &= \int_{\mathbb{R}} x \, d\mathbb{P}_X \\
&= \sum_{k=1}^{\infty} p_k \underbrace{\int_{\mathbb{R}} x \, d\delta_{x_k}}_{=x_k} \\
&= \sum_{k=1}^{\infty} p_k x_k
\end{aligned}$$

Proposition. Soit $X : \Omega \to E$ une variable aléatoire. La loi de X est caractérisée par les quantités $\mathbb{E}[h(X)]$ où $h : E \to \mathbb{R}$ décrit l'ensemble des fonctions mesurables bornées.
C'est-à-dire, si X et X' sont deux variables aléatoires vérifiant

$$\mathbb{E}[h(X)] = \mathbb{E}[h(X')]$$

pour toute fonction h mesurable bornée, alors X et X' ont la même loi.

Démonstration. Soient X et X' telles que $\mathbb{E}[h(X)] = \mathbb{E}[h(X')]$ pour toute fonction h mesurable bornée.
Soit $A \in \mathscr{E}$. On pose $h = \mathbb{1}_A$ et alors

$$\mathbb{P}(X \in A) = \mathbb{E}[\mathbb{1}_A(X)] = \mathbb{E}[h(X)] = \mathbb{E}[h(X')] = \mathbb{E}[\mathbb{1}_A(X')] = \mathbb{P}(X' \in A)$$

Donc X et X' ont la même loi. □

Exemples 3.4. On considère une variable aléatoire X de loi uniforme sur $]0,1[$ et on pose $Y = -\ln(X)$. Déterminons la loi de Y.
Soit h une fonction mesurable bornée. Alors

$$\begin{aligned}
\mathbb{E}[h(Y)] &= \mathbb{E}[h(-\ln(X))] \\
&= \int_{\mathbb{R}} h(-\ln(x)) \, d\mathbb{P}_X(x) \\
&= \int_{\mathbb{R}} h(-\ln(x)) \underbrace{\mathbb{1}_{]0,1[}(x) \, d\lambda_1(x)}_{=\mathbb{P}_X} \\
&= \int_{\mathbb{R}} h(y) \underbrace{\mathbb{1}_{]0,\infty[}(y) e^{-y} \, d\lambda_1(y)}_{=\mathbb{P}_X} \qquad \text{avec } y = -\ln(x)
\end{aligned}$$

D'après la proposition précédente, la loi de Y est

$$\mathbb{1}_{]0,\infty[}(y)e^{-y}\lambda_1(y)$$

c'est-à-dire que Y suit une loi exponentielle de paramètre 1.

3.5 Moments d'ordre p

Pour $p \in [1, \infty[$, on définit l'espace $\mathscr{L}^p(\Omega, \mathscr{F}, \mathbb{P})$ comment l'ensemble des variables aléatoires vérifiant

$$\|X\|_p = \left(\int_\Omega |X(\omega)|^p \, d\mathbb{P}(\omega) \right)^{\frac{1}{p}} < \infty$$

On a bien que $\|\cdot\|_p$ est une norme qui rend $\mathscr{L}^p(\Omega, \mathscr{F}, \mathbb{P})$ complet (toute suite de Cauchy converge). Dans le cas $p = \infty$, on pose

$$\|X\|_\infty = \sup_{\omega \in \Omega} |X(\omega)| = \lim_{p \to \infty} \|X\|_p$$

Donc $\mathscr{L}^\infty(\Omega, \mathscr{F}, \mathbb{P})$ est l'ensemble des variables aléatoires bornées.

Définition 3.6. Soit $p \in [1, \infty[$ et X une variable aléatoire dans $\mathscr{L}^p(\Omega, \mathscr{F}, \mathbb{P})$. Le **moment d'ordre p** de X est

$$\mathbb{E}[X^p] = \int_\Omega X(\omega)^p \, d\mathbb{P}(\omega) = \int_\mathbb{R} x^p \, d\mathbb{P}_X(x)$$

Remarque.

1. Le moment d'ordre 1 correspond à l'espérance.
2. Si $p \leq q$ alors $\mathscr{L}^q(\Omega, \mathscr{F}, \mathbb{P}) \subset \mathscr{L}^p(\Omega, \mathscr{F}, \mathbb{P})$
   En particulier, si X admet un moment d'ordre q alors X admet un moment d'ordre p pour tout $p \leq q$

Proposition. Soit X une variable aléatoire réelle positive et $p \in [1, \infty[$. Alors, pour tout $t > 0$, on a

$$\mathbb{P}(X \geq t) \leq \frac{\mathbb{E}[X^p]}{t^p}$$

Cette inégalité permet de contrôler le comportement à l'infini de X.

Démonstration. On part de l'inégalité

$$t^p \mathbb{1}_{\{X \geq t\}} \leq X^p$$

On applique l'espérance

$$t^p \mathbb{E}\left[\mathbb{1}_{\{X \geq t\}}\right] \leq \mathbb{E}[X^p]$$
$$\mathbb{P}(X \geq t) \leq \frac{\mathbb{E}[X^p]}{t^p}$$

□

Le cas $\mathscr{L}^2(\Omega, \mathscr{F}, \mathbb{P})$:
On rappelle que $\mathscr{L}^2(\Omega, \mathscr{F}, \mathbb{P})$ est muni d'un produit scalaire

$$\langle X, Y \rangle = \mathbb{E}[XY] = \int_\Omega X(\omega)Y(\omega) \, d\mathbb{P}(\omega)$$

La norme associée est

$$\|X\|_2 = \sqrt{\langle X, X \rangle} = \sqrt{\int_\Omega X(\omega)^2 \, d\mathbb{P}(\omega)}$$

Définition 3.7. La **variance** d'une variable aléatoire réelle X est le moment d'ordre 2 de $X - \mathbb{E}[X]$, soit

$$\mathsf{Var}(X) = \|X - \mathbb{E}[X]\|_2^2 = \int_\Omega (X(\omega) - \mathbb{E}[X])^2 \, d\mathbb{P}(\omega),$$

qui est bien définie si $X \in \mathscr{L}^2(\Omega, \mathscr{F}, \mathbb{P})$.
On définit **l'écart-type** par

$$\sigma(X) = \sqrt{\mathsf{Var}(X)} = \|X - \mathbb{E}[X]\|_2$$

Remarque.

1. En développant le carré dans la définition de la variance, on obtient

$$\mathsf{Var}(X) = \mathbb{E}\left[X^2\right] - \mathbb{E}[X]^2$$

2. On a $\mathsf{Var}(X) = 0$ si et seulement si X est constante.

Proposition. Soit X une variable aléatoire dans $\mathscr{L}^2(\Omega, \mathscr{F}, \mathbb{P})$. Alors, pour tout $t > 0$, on a

$$\mathbb{P}\left(|X - \mathbb{E}[X]|_2 \geq t\right) \leq \frac{\mathsf{Var}(X)}{t^2}$$

Définition 3.8. Soient X et Y deux variables aléatoires dans $\mathscr{L}^2(\Omega, \mathscr{F}, \mathbb{P})$. On définit la **covariance** de X et Y par

$$\mathrm{COV}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \langle X - \mathbb{E}[X], Y - \mathbb{E}[Y]\rangle$$

où on rappelle que

$$\langle U, V\rangle = \mathbb{E}[UV] = \int_\Omega U(\omega)V(\omega)\, d\mathbb{P}(\omega)$$

Par les propriétés du produit scalaire dans $\mathscr{L}^2(\Omega, \mathscr{F}, \mathbb{P})$, on en déduit que la covariance est symétrique, bilinéaire et positive :

$$\mathrm{COV}(X, X) = \mathsf{Var}(X) \geq 0$$

Par ailleurs, on a aussi la relation de Pythagore :

$$\mathsf{Var}(X + Y) = \mathsf{Var}(X) + \mathsf{Var}(Y) + 2\mathrm{COV}(X, Y)$$

3.9 Moments de lois usuelles

Sous forme de tableau :

Loi	Espérance	Variance
$\mathcal{U}(\{1, \ldots, n\})$	$\frac{n+1}{2}$	$\frac{n^2-1}{12}$
$\mathcal{B}(p)$	p	$p(1-p)$
$\mathcal{B}(n, p)$	np	$np(1-p)$
$\mathcal{G}(p)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
$\mathcal{P}(\theta)$	θ	θ
$\mathcal{U}([a, b])$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
$\mathcal{E}(\theta)$	$\frac{1}{\theta}$	$\frac{1}{\theta^2}$
$\mathcal{N}(\mu, \sigma^2)$	μ	σ^2

4 Fonctions associées à une variable aléatoire

4.1 Fonction de répartition

Définition 4.2. Soit X une variable aléatoire réelle. La **fonction de répartition** de X est la fonction

$$F_X : \mathbb{R} \to [0, 1], \quad t \mapsto \mathbb{P}(X \leq t)$$

Exemple. Si X est une variable réelle de densité f_X par rapport à la mesure de Lebesgue ($\mathbb{P}_X = f_X\lambda_1$), alors

$$\mathbb{P}_X(A) = \int_A f_X(t)\,d\lambda_1(t)$$

Donc, la fonction de répartition de X est donnée par

$$F_X(t) = \mathbb{P}_X([-\infty, t]) = \int_{-\infty}^t f_X(u)\,d\lambda_1(u)$$

Par exemple, si $X \sim \mathcal{E}(\theta)$, c'est-à-dire

$$f_X(t) = \theta e^{-\theta t}\mathbb{1}_{\mathbb{R}_+}(t)$$

alors

$$\begin{aligned} F_X(t) &= \int_{-\infty}^t \theta e^{-\theta u}\mathbb{1}_{\mathbb{R}_+}(u)\,d\lambda_1(u) \\ &= \begin{cases} 0 & \text{si } t < 0 \\ \left[-e^{-\theta u}\right]_0^t & \text{si } t \geq 0 \end{cases} \\ &= \left(1 - e^{-\theta t}\right)\mathbb{1}_{\mathbb{R}_+}(t) \end{aligned}$$

De manière générale, l'égalité $F_X(t) = \int_{-\infty}^t f_X(u)\,d\lambda_1(u)$ assure que F_X est dérivable λ_1-p.p, avec $F_X'(t) = f_X(t)$ pour λ_1-presque tout $t \in \mathbb{R}$.

Exemple. On considère $X \sim \mathcal{B}(p)$ et $\mathbb{P}_X = (1-p)\delta_0 + p\delta_1$. Alors, la fonction de répartition de X est donnée par

$$\begin{aligned} F_X(t) &= \mathbb{P}_X([-\infty, t]) \\ &= (1-p)\delta_0([-\infty, t]) + p\delta_1([-\infty, t]) \\ &= \begin{cases} 0 & \text{si } t < 0 \\ 1-p & \text{si } 0 \leq t < 1 \\ 1 & \text{si } t \geq 1 \end{cases} \end{aligned}$$

Plus généralement, si X est une variable aléatoire discrète de loi $\mathbb{P}_X = \sum_{k\in E} p_k\delta_{x_k}$, avec les x_k ordonnés, alors

$$F_X(t) = \sum_{k=0}^{\infty} p_k\delta_{x_k}([-\infty, t]) = \sum_{k=0}^{\infty} p_k\mathbb{1}_{[x_k, +\infty[}(t)$$

Proposition. Soit X une variable aléatoire réelle de fonction de répartition F_X. Alors

1. F_X est croissante, continue à droite et admet des limites à gauche (càdlàg)
2. Les limites de F_X en $-\infty$ et $+\infty$ sont

$$\lim_{t\to\infty} F_X(t) = 1, \quad \lim_{t\to-\infty} F_X(t) = 0$$

3. En posant

$$F_X(t-) = \lim_{\substack{\varepsilon\to 0 \\ \varepsilon>0}} F_X(t-\varepsilon)$$

On a

$$F_X(t-) = \mathbb{P}(X < t) = \mathbb{P}(X \leq t)$$

et donc

$$\mathbb{P}(X = t) = F_X(t) - F_X(t-)$$

Démonstration. Admise (ou a faire en exercice) □

Proposition. La fonction de répartition d'une variable aléatoire X caractérise sa loi. C'est à dire que deux variables aléatoires ayant la même fonction de répartition ont la même loi.

Démonstration. Si $F_X = F_Y$ alors les mesures de probabilités $\mathbb{P}_X$ et $\mathbb{P}_Y$ associées à X et Y coïncident sur les ensembles de la forme $[-\infty, t]$. Ces ensembles engendrent la tribu borélienne de $\mathbb{R}$ et sont stables par intersection finie, donc le lemme de classes monotones assure que $\mathbb{P}_X = \mathbb{P}_Y$. □

4.3 Fonction caractéristique

Définition 4.4. Soit X une variable aléatoire réelle. La **fonction caractéristique** de X est la fonction

$$\begin{aligned} \varphi_X : \mathbb{R} &\to \mathbb{C} \\ t &\mapsto \mathbb{E}\left[e^{itX}\right] = \int_\Omega e^{itX(\omega)}\, d\mathbb{P}(\omega) \end{aligned}$$

Remarque.

1. La fonction caractéristique est bien définie car

$$\int_\Omega \left|e^{itX(\omega)}\right| d\mathbb{P}(\omega) = \int_\Omega d\mathbb{P}(\omega) = 1$$

2. La fonction caractéristique correspond à un signe près à la transformée de Fourier de la variable aléatoire X.

Exemple.

- Soit $X \sim \mathcal{B}(p)$. Alors

$$\varphi_X(t) = \mathbb{E}\left[e^{itX}\right] = (1-p)e^{it0} + pe^{it1} = 1 - p + pe^{it}$$

- Soit X une variable aléatoire discrète de loi $\mathbb{P}_X = \sum_{k\in E} p_k \delta_{x_k}$. Alors

$$\varphi_X(t) = \mathbb{E}\left[e^{itX}\right] = \sum_{k\in E} p_k e^{itx_k}$$

- Soit $X \sim \mathcal{U}([a,b])$. Alors

$$\begin{aligned} \varphi_X(t) &= \mathbb{E}\left[e^{itX}\right] \\ &= \int_\mathbb{R} e^{itx} \frac{1}{b-a} \mathbb{1}_{[a,b]}(x)\, d\lambda_1(x) \\ &= \left[\frac{e^{itx}}{it}\right]_a^b \\ &= \frac{e^{itb} - e^{ita}}{it(b-a)} \quad \text{si } t \neq 0 \end{aligned}$$

et pour $t = 0$, on a

$$\varphi_X(0) = \mathbb{E}\left[e^{i0X}\right] = \mathbb{E}[1] = 1$$

- Soit $X \sim \mathcal{N}(0,1)$. Alors

$$\varphi_X(t) = \mathbb{E}\left[e^{itX}\right] = \int_\mathbb{R} e^{itx} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}\, d\lambda_1(x) = e^{-\frac{t^2}{2}}$$

cf. TD4 pour le calcul de l'intégrale.

Proposition. Soit X une variable aléatoire réelle. Si X admet un moment d'ordre $p \in \mathbb{N}$, alors la fonction caractéristique φ_X est de classe $\mathscr{C}^p$ et

$$\mathbb{E}[X^p] = (-i)^p \varphi_X^{(p)}(0)$$

Démonstration. La fonction $g : (t, \omega) \mapsto e^{itX(\omega)}$ est intégrable par rapport à ω, dérivable par rapport à t et vérifie

$$\left|\frac{\partial g}{\partial t}(t,\omega)\right| = \left|iX(\omega)e^{itX(\omega)}\right| = |X(\omega)|$$

Donc si X admet un moment d'ordre 1, alors

$$\left|\frac{\partial g}{\partial t}(t,\omega)\right| = |X(\omega)|$$

qji est intégrable, donc le théorème de dérivation sous le signe intégral assure que

$$\varphi_X'(t) = \int_\Omega iX(\omega)e^{itX(\omega)}\, d\mathbb{P}(\omega)$$

en particulier, en $t = 0$, on a

$$\varphi_X'(0) = i\mathbb{E}[X]$$

On raisonne ensuite par récurrence sur p pour les autres moments. □

Théorème. La fonction caractéristique φ_X caractérise la loi de X. C'est-à-dire que si $\varphi_X = \varphi_Y$ alors X et Y ont la même loi.

Démonstration. Admise, elle est basée sur l'injectivié de la transformée de Fourier de mesures. □

4.5 Fonction génératrice

On considère ici des variables aléatoires à valeurs dans $\mathbb{N}$.

Définition 4.6. Soit X une variable aléatoire à valeurs dans $\mathbb{N}$. La **fonction génératrice** de X est la série entière

$$G_X(z) = \mathbb{E}\left[z^X\right] = \sum_{n=0}^{\infty} \mathbb{P}(X = n) z^n$$

Comme $\sum_{n=0}^{\infty} \mathbb{P}(X = n) = 1$, on en déduit que le rayon de convergence de cette série entière est au moins 1, donc G_X est définie sur $[-1, 1]$ et continue sur $[-1, 1]$. Par ailleurs, G_X est de classe $\mathscr{C}^\infty$ sur $]-1, 1[$ avec

$$\mathbb{P}(X = n) = \frac{G_X^{(n)}(0)}{n!}$$

Donc G_X caractérise la loi de X.
En dérivant G_X terme à terme, on obtient

$$G_X'(z) = \sum_{n=1}^{\infty} n\mathbb{P}(X = n) z^{n-1} = \mathbb{E}\left[X z^{X-1}\right]$$

On prend une suite $(z_k)_{k\in\mathbb{N}}$ qui croit vers 1. Alors, la suite des fonctions $\left(X {z_k}^{X-1}\right)_k$ est croissante, positive et donc par le théorème de convergence monotone, on a

$$\mathbb{E}\left[\lim_{k\to\infty} X {z_k}^{X-1}\right] = \lim_{k\to\infty} \underbrace{\mathbb{E}\left[X {z_k}^{X-1}\right]}_{G_X'(z_k)}$$

d'où

$$\mathbb{E}[X] = \lim_{\substack{z\to 1\\ z<1}} G_X'(z)$$

On peut noter $G_X'(1-) = \lim_{\substack{z\to 1\\ z<1}} G_X'(z)$.
Bref, si X admet un moment d'ordre 1, alors $G_X'(1-) = \mathbb{E}[X]$.

Plus généralement, on peut montrer que

$$G_X^{(k)}(1-) = \mathbb{E}[X(X-1)\dots(X-k+1)]$$

pour tout $k \in \mathbb{N}$. Cela permet de déterminer les moments de X.

Exemple. ▷ Soit $X \sim \mathcal{B}(p)$. Alors

$$G_X(z) = \mathbb{E}\left[z^X\right] = (1-p)z^0 + pz^1 = 1-p+pz$$

et donc

$$G'_X(z) = p$$

donc

$$\mathbb{E}[X] = G'_X(1) = p$$

▷ Soit $X \sim \mathcal{B}(n,p)$. Alors

$$\begin{aligned} G_X(z) = \mathbb{E}\left[z^X\right] &= \sum_{k=0}^{n} \binom{n}{k} p^k (1-p)^{n-k} z^k \\ &= (pz+1-p)^n \end{aligned}$$

donc

$$G'_X(z) = np(pz+1-p)^{n-1}$$

et donc

$$\mathbb{E}[X] = G'_X(1) = np$$

▷ Soit $X \sim \mathcal{G}(p)$. Alors

$$\begin{aligned} G_X(z) = \mathbb{E}\left[z^X\right] &= \sum_{k=1}^{\infty} p(1-p)^{k-1} z^k \\ &= zp \sum_{k=1}^{\infty} (1-p)z^{k-1} \\ &= \frac{zp}{1-(1-p)z} \end{aligned}$$

et

$$\mathbb{E}[X] = G'_X(1) \to \text{exercice}$$

▷ Soit $X \sim \mathcal{P}(\theta)$. Alors

$$\begin{aligned} G_X(z) = \mathbb{E}\left[z^X\right] &= \sum_{k=0}^{\infty} e^{-\theta} \frac{\theta^k}{k!} z^k \\ &= e^{-\theta} \sum_{k=0}^{\infty} \frac{(\theta z)^k}{k!} \\ &= e^{-\theta} e^{\theta z} \\ &= e^{\theta(z-1)} \end{aligned}$$

donc

$$G'_X(z) = \theta e^{\theta(z-1)}$$

et donc

$$\mathbb{E}[X] = G'_X(1) = \theta$$

Chapitre 2 — Indépendance

On considère ici $(\Omega, \mathscr{F}, \mathbb{P})$ un espace probabilisé.

5 Indépendances d'événements

5.1 Conditionnement

Si $A \in \mathscr{F}$ est un événement tel que $\mathbb{P}(A) > 0$, alors la **probabilité conditionnelle de $B \in \mathscr{F}$ sachant A** est définie par

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

alors, l'application

$$\begin{aligned} \mathbb{P}_A : \mathscr{F} &\to [0,1] \\ B &\mapsto \mathbb{P}_A(B) = \mathbb{P}(B|A) \end{aligned}$$

est une probabilité sur $(\Omega, \mathscr{F})$. Intuitivement, l'espace probabilisé $(\Omega, \mathscr{F}, \mathbb{P}_A)$ correspond à une expérience aléatoire où l'on sait a priori que l'événement A est vérifié.
Si A et B sont deux événements de probabilité strictement positive, alors

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A|B)\mathbb{P}(B)}{\mathbb{P}(A)} \qquad \text{formule de Bayes.}$$

5.2 Quelques formules

Une partition $(A_i)_{i\in I}$ avec $I \subset \mathbb{N}$ formée d'événements A_i est une famille d'événements vérifiant

- $\forall i, j \in I, i \neq j \implies A_i \cap A_j = \varnothing$,
- $\bigcup_{i\in I} A_i = \Omega$.

Dans ce cas, on a la **formule des probabilités totales** :

$$\mathbb{P}(B) = \sum_{i\in I} \mathbb{P}(A_i)\mathbb{P}(B|A_i).$$

pour tout événement $B \in \mathscr{F}$ et $\mathbb{P}(A_i) > 0$ pour tout $i \in I$.
Cas particulier : avec la partition $(A, \overline{A})$, on a

$$\mathbb{P}(B) = \mathbb{P}(A)\mathbb{P}(B|A) + \mathbb{P}(A^C)\mathbb{P}(B|A^C).$$

où $A^C = \{\omega \in \Omega \mid \omega \notin A\}$ est le complémentaire de A.
On peut alors étendre la formule de Bayes à une partition $(A_i)_{i\in I}$ de Ω :

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\sum_{j\in I} \mathbb{P}(B|A_j)\mathbb{P}(A_j)}.$$

Cas particulier : avec la partition $(A, \overline{A})$, on a

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A)\mathbb{P}(B|A)}{\mathbb{P}(A)\mathbb{P}(B|A) + \mathbb{P}(A^C)\mathbb{P}(B|A^C)}.$$

> **Exemple.** On se place dans la cas d'une maladie qui touche une personne sur 100. Si une personne est malade (noté M), alors le test est positif dans 99% des cas. Si une personne n'est pas malade (noté M^C), alors le test est positif dans 1% des cas.
> Notons P l'événement « le test est positif ». Alors, si un test est positif, la probabilité que la

personne soit malade est donnée par

$$\begin{aligned}\mathbb{P}(M|P) &= \frac{\mathbb{P}(P|M)\mathbb{P}(M)}{\mathbb{P}(P|M)\mathbb{P}(M) + \mathbb{P}(P|M^C)\mathbb{P}(M^C)} \\ &= \frac{0.99 \times 0.01}{0.99 \times 0.01 + 0.01 \times 0.99} \\ &= \frac{1}{2}.\end{aligned}$$

Définition 5.3. Deux événements A et B sont **indépendants** si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

En particulier,

$$\mathbb{P}(B|A) = \mathbb{P}(B) \quad \text{et} \quad \mathbb{P}(A|B) = \mathbb{P}(A).$$

Exemple. On lance 2 dés. On a alors

$$\Omega = \{1, 2, \dots, 6\}^2, \quad \mathscr{F} = \mathscr{P}(\Omega), \quad \mathbb{P} = \text{probabilité uniforme}.$$

On considère les événements

$$A = \{6\} \times \{1, \dots, 6\}, \quad B = \{1, \dots, 6\} \times \{6\}.$$

Alors,

$$\mathbb{P}(A) = \mathbb{P}(B) = \frac{1}{6},$$

et

$$\mathbb{P}(A \cap B) = \mathbb{P}(\{6\} \times \{6\}) = \frac{1}{36} = \mathbb{P}(A)\mathbb{P}(B).$$

Donc A et B sont indépendants

Définition 5.4. Des événements $A_1, \dots, A_n \in \mathscr{F}$ sont **indépendants** si

$$\forall I \subset \{1, \dots, n\}, I \neq \varnothing, \quad \mathbb{P}\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} \mathbb{P}(A_i).$$

Plus généralement, une famille d'événements $(A_i)_{i \in I}$ est indépendante si toute sous-famille finie est constituée d'événements indépendants.

Exemple. On lance 2 dés. On considère les événements

$$\begin{aligned} A &= \text{le premier dé est pair}, \\ B &= \text{le deuxième dé est pair}, \\ C &= \text{la somme des dés est paire}. \end{aligned}$$

Alors,

$$\begin{aligned}
\mathbb{P}(A) &= \frac{1}{2},\\
\mathbb{P}(B) &= \frac{1}{2},\\
\mathbb{P}(A \cap B) &= \frac{1}{4},\\
\mathbb{P}(C) &= \frac{1}{2},\\
\mathbb{P}(A \cap C) &= \frac{1}{4},\\
\mathbb{P}(B \cap C) &= \frac{1}{4},
\end{aligned}$$

Donc les événements A et B, A et C, B et C sont indépendants respectivement.
Par ailleurs, on a

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A \cap B) = \frac{1}{4} \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = \frac{1}{8}.$$

Donc les événements A, B et C ne sont pas indépendants.

Remarque. L'indépendance d'événements $A_1, \ldots A_n$ implique l'indépendance de $A_1^c, A_2, \ldots, A_n$ (et de même en passant au complémentaire sur d'autres indices). En particulier, si A et B sont indépendants, alors A et B^c sont indépendants.

6 Indépendance de variables aléatoires

Définition 6.1. Soient $X_1, \ldots, X_n$ des variables aléatoires à valeurs dans $(E_1, \mathscr{E}_1), \ldots, (E_n, \mathscr{E}_n)$. On dit que ces variables aléatoires sont **indépendantes** si pour tout $B_1 \in \mathscr{E}_1, \ldots, B_n \in \mathscr{E}_n$, les événements $\{X_1 \in B_1\}, \ldots, \{X_n \in B_n\}$ sont indépendants :

$$\mathbb{P}(X_1 \in B_1, \ldots, X_n \in B_n) = \prod_{i=1}^{n} \mathbb{P}(X_i \in B_i).$$

Cetté égalité se réécrit

$$\begin{aligned}
\mathbb{P}((X_1, \ldots, X_n) \in B_1 \times \cdots \times B_n) &= \prod_{i=1}^{n} \mathbb{P}(X_i \in B_i)\\
\mathbb{P}_{(X_1, \ldots, X_n)}(B_1 \times \cdots \times B_n) &= \prod_{i=1}^{n} \mathbb{P}_{X_i}(B_i).
\end{aligned}$$

Cela signifie que

$$\mathbb{P}_{(X_1, \ldots, X_n)} = \mathbb{P}_{X_1} \otimes \cdots \otimes \mathbb{P}_{X_n}.$$

Plus généralement, une famille de variables aléatoires $(X_i)_{i \in I}$ est indépendante si toute sous-famille finie l'est.

Proposition. Soit $X_1, \ldots, X_n$ des variables aléatoires à valeurs dans $(E_1, \mathscr{E}_1), \ldots, (E_n, \mathscr{E}_n)$. Les assertions suivantes sont équivalentes :

1. Les variables aléatoires $X_1, \ldots, X_n$ sont indépendantes.
2. Pour toutes fonctions $h_1 : E_1 \to \mathbb{R}, \ldots, h_n : E_n \to \mathbb{R}$ positives ou intégrables pour $(\mathscr{L}^1(E_k, \mathscr{E}_k, \mathbb{P}_{X_k}))$, on a

$$\mathbb{E}\left[h_1(X_1) \cdots h_n(X_n)\right] = \mathbb{E}[h_1(X_1)] \cdots \mathbb{E}[h_n(X_n)].$$

Démonstration. ▷ On montre que 1. implique 2.

On considère le vecteur aléatoire

$$\begin{aligned} X = (X_1, \dots, X_n) : \Omega &\to E_1 \times \cdots \times E_n, \\ \omega &\mapsto (X_1(\omega), \dots, X_n(\omega)). \end{aligned}$$

Alors

$$\begin{aligned} \mathbb{E}\left[h_1(X_1)\cdots h_n(X_n)\right] &= \int_\Omega h_1(X_1(\omega))\cdots h_n(X_n(\omega))\, d\mathbb{P}(\omega) \\ &\underset{\text{transfert}}{\overset{\text{formule de}}{=}} \int_{E_1\times\cdots\times E_n} h_1(x_1)\cdots h_n(x_n)\, d\mathbb{P}_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \\ &= \int_{E_1\times\cdots\times E_n} h_1(x_1)\cdots h_n(x_n)\, d\left(\mathbb{P}_{X_1}\otimes\cdots\otimes\mathbb{P}_{X_n}\right)(x_1,\dots,x_n) \\ &\underset{\text{Tonelli}}{\overset{\text{Fubini}}{=}} \int_{E_n}\int_{E_{n-1}}\cdots\int_{E_1} h_1(x_1)\cdots h_n(x_n)\, d\mathbb{P}_{X_1}(x_1)\cdots d\mathbb{P}_{X_n}(x_n) \\ &= \int_{E_1} h_1(x_1)\, d\mathbb{P}_{X_1}(x_1)\cdots\int_{E_n} h_n(x_n)\, d\mathbb{P}_{X_n}(x_n) \\ &= \mathbb{E}[h_1(X_1)]\cdots\mathbb{E}[h_n(X_n)]. \end{aligned}$$

▷ On montre que 2. implique 1.
Soit $A_1 \in \mathscr{E}_1, \dots, A_n \in \mathscr{E}_n$. On pose $h_i = \mathbb{1}_{A_i}(x_i)$. Alors

$$\mathbb{E}\left[h_1(X_1)\cdots h_n(X_n)\right] = \mathbb{E}\left[h_1(X_1)\right]\cdots\mathbb{E}\left[h_n(X_n)\right]$$

se réécrit

$$\mathbb{E}\left[\mathbb{1}_{A_1}(X_1)\cdots\mathbb{1}_{A_n}(X_n)\right] = \mathbb{E}\left[\mathbb{1}_{A_1}(X_1)\right]\cdots\mathbb{E}\left[\mathbb{1}_{A_n}(X_n)\right]$$

et donc

$$\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \mathbb{P}(X_1 \in A_1)\cdots\mathbb{P}(X_n \in A_n).$$

□

Exemple. Si X_1 et X_2 sont des variables aléatoires intégrables et indépendantes, alors

$$\mathbb{E}[X_1X_2] = \mathbb{E}[X_1]\mathbb{E}[X_2].$$

En particulier,

$$\mathsf{Cov}(X_1, X_2) = \mathbb{E}[X_1X_2] - \mathbb{E}[X_1]\mathbb{E}[X_2] = 0.$$

et donc

$$\mathsf{Var}(X_1 + X_2) = \mathsf{Var}(X_1) + \mathsf{Var}(X_2) + 2\,\mathsf{Cov}(X_1, X_2) = \mathsf{Var}(X_1) + \mathsf{Var}(X_2).$$

Exemple. Soit $t \in \mathbb{R}$ fixé et X_1, X_2 deux variables aléatoires réelles indépendantes. Avec $h_j(x_j) = e^{itx_j}$, $j = 1, 2$, on obtient

$$\mathbb{E}\left[e^{itX_1}e^{itX_2}\right] = \mathbb{E}\left[e^{itX_1}\right]\mathbb{E}\left[e^{itX_2}\right].$$

c'est-à-dire

$$\varphi_{X_1+X_2}(t) = \varphi_{X_1}(t)\varphi_{X_2}(t).$$

7 Critères d'indépendance

Cas dscrèt

Soit X et Y deux variables aléatoires à valeurs dans des espaces discrets E et F. Elles sont indépendantes si et seulement si

$$\mathbb{P}\left(X = x, Y = y\right) = \mathbb{P}(X = x)\mathbb{P}(Y = y)$$

pour tout $x \in E$ et $y \in F$.

En effet, si $A \subset E$ et $B \subset F$, alors

$$\begin{aligned}\mathbb{P}(X \in A, Y \in B) &= \mathbb{P}(X \in \cup_{x\in A}\{x\}, Y \in \cup_{y\in B}\{y\}) \\ &= \sum_{\substack{x\in A\\ y\in B}} \mathbb{P}(X = x, Y = y)\end{aligned}$$

Avec les fonctions de répartition

Soient X et Y deux variables aléatoires à valeurs réelles. Elles sont indépendantes si et seulement si pour tout $x, y \in \mathbb{R}$,

$$\mathbb{P}(X \le x, Y \le y) = \mathbb{P}(X \le x)\mathbb{P}(Y \le y).$$

c'est-à-dire

$$F_{X,Y}(x,y) = F_X(x)F_Y(y).$$

Avec les fonctions caractéristiques

Soient X_1, X_2 deux variables aléatoires à valeurs réelles. Elles sont indépendantes si et seulement si

$$\begin{aligned}\mathbb{E}\left[e^{it_1X_1}e^{it_2X_2}\right] &= \mathbb{E}\left[e^{it_1X_1}\right]\mathbb{E}\left[e^{it_2X_2}\right] \\ \mathbb{E}\left[e^{i(t_1X_1+t_2X_2)}\right] &= \mathbb{E}\left[e^{it_1X_1}\right]\mathbb{E}\left[e^{it_2X_2}\right].\end{aligned}$$

c'est-à-dire

$$\varphi_{(X_1+X_2)}(t_1+t_2) = \varphi_{X_1}(t_1)\varphi_{X_2}(t_2).$$

Cas des variables aléatoires à densité

Soit (X_1, X_2) un vecteur aléatoire de densité $f_{(X_1,X_2)}$ par rapport à λ_2 (mesure de Lebesgue sur $\mathbb{R}^2$). On suppose que

$$f_{(X_1,X_2)}(x_1,x_2) = f_1(x_1)f_2(x_2)$$

avec $f_j : \mathbb{R} \to \mathbb{R}_+$ positive et vérifiant

$$\int_{\mathbb{R}} f_j(x)\, d\lambda_1(x) = 1.$$

Alors les variables aléatoires X_1 et X_2 sont indépendantes de densité respectives f_1 et f_2.

> **Exemple.** Soit (X, Y) un vecteur aléatoire de densité
>
> $$f(x,y) = \frac{1}{2\pi}e^{-\frac{x^2+y^2}{2}}.$$
>
> Alors,
>
> $$f(x,y) = \frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}$$
>
> donc les variables aléatoires X et Y sont indépendantes et suivent toutes les deux une loi normale centrée réduite.